Instituto Tecnológico de Pabellón de Arteaga

Ingeniería en Tecnologías de la Información y Comunicaciones

Tarea 2.1
Lectura guiada

Nombre de estudiante
Jonathan de Jesus Garcia Rodriguez

Número de control
221050153

Grupo
ITIC9

Materia
Visión Artificial

Docente
Eduardo Flores Gallegos

Fecha
23 de septiembre de 2026

1. ¿Qué es la visión artificial y cómo interactúan reconocimiento, reconstrucción y reorganización?

Es el campo de la inteligencia artificial que permite procesar e interpretar imágenes y videos para extraer información útil. IBM explica tres procesos que se informan mutuamente: el reconocimiento identifica entidades o acciones; la reconstrucción obtiene sus características tridimensionales y la reorganización infiere cómo se relacionan.

En una escena vial, el sistema puede reconocer automóviles, estimar su disposición espacial y deducir qué vehículo está delante de otro. Los tres procesos contribuyen a comprender la escena, aunque cada uno responde una pregunta distinta: qué aparece, cómo se representa en el espacio y qué relación existe entre sus elementos.

2. ¿En qué difieren una CNN y un transformador de visión ViT?

Una red neuronal convolucional (CNN) extrae patrones visuales mediante filtros que recorren regiones de la imagen: sus capas de agrupación reducen la representación y las capas finales pueden clasificarla.

Un transformador de visión (ViT) divide la imagen en parches, los trata como una secuencia comparable a los tokens de un modelo de lenguaje y aplica autoatención para construir una representación de la imagen. Así, la CNN organiza el procesamiento alrededor de filtros espaciales, mientras que el ViT aprende relaciones entre parches mediante atención.

3. ¿Cómo se distinguen clasificación, detección y segmentación?

La clasificación asigna una clase a una imagen o a un objeto: por ejemplo, una radiografía normal o con indicios de neumonía. La detección, además de indicar qué objetos hay, los localiza mediante cuadros delimitadores, por ejemplo, ubica varios vehículos en una calle.

La segmentación trabaja a nivel de píxel y delimita sus contornos con mayor precisión. En la segmentación semántica cada píxel recibe una categoría, de modo que dos autos pueden pertenecer a la misma región de clase **automóvil**. La segmentación de instancias separa cada auto como objeto individual y define el contorno de cada uno.

4. ¿Por qué importa el preprocesamiento y cómo se amplía el conjunto de datos?

La calidad y diversidad de los datos condicionan lo que aprende el modelo y la precisión de sus resultados. IBM menciona limpieza y mejoras de imagen, como ajustes de brillo o contraste, cambio de tamaño y suavizado. Para ampliar el conjunto de entrenamiento describe el aumento de datos, que crea variantes de

imágenes existentes mediante transformaciones como rotaciones e inversiones, y la generación de datos sintéticos, que añade imágenes producidas artificialmente.

Estas técnicas pueden aportar variedad, pero las transformaciones deben conservar el significado de la etiqueta, una imagen modificada de forma inadecuada puede introducir errores en lugar de ayudar.

5. ¿Qué hace la capa convolucional de una CNN?

Extrae características de los píxeles originales. Un filtro o kernel, formado por pesos, se aplica a pequeñas regiones de la imagen y se desplaza por ella; en cada posición combina los valores del filtro y los píxeles. El resultado es un mapa de características que responde a ciertos patrones. Distintos filtros pueden captar colores, bordes, formas y texturas.

En el ejemplo de radiografías del artículo, esos patrones pueden incluir contornos pulmonares asimétricos, zonas brillantes u opacas y texturas irregulares. Las capas posteriores reducen y combinan la información hasta producir una predicción.

6. ¿Cómo evolucionó la visión artificial hasta el aprendizaje profundo?

En las décadas de 1950 y 1960 se investigó cómo responden los sistemas visuales a rasgos simples, como líneas y bordes, y comenzaron la digitalización de imágenes y la reconstrucción de formas tridimensionales.

En 1982, David Marr propuso un procesamiento jerárquico de esquinas, curvas y formas; Kunihiko Fukushima desarrolló el neocognitrón, antecedente de las redes convolucionales.

Hacia 2000 predominaban la clasificación de imágenes y el reconocimiento de objetos. ImageNet, introducido en 2009, proporcionó millones de imágenes etiquetadas.

En 2012, AlexNet, entrenada con ImageNet, redujo de manera importante el error de reconocimiento y mostró el potencial práctico del aprendizaje profundo para aprender características directamente de grandes conjuntos de imágenes.

7. ¿Cómo ayuda el sistema en el ejemplo hipotético de neumonía?

En el ejemplo hipotético, una CNN analiza radiografías etiquetadas, identifica patrones pulmonares anómalos y estima la probabilidad de neumonía. Si supera un umbral, marca la imagen para revisión del radiólogo.

8. ¿Qué aplicaciones se describen en automoción, fabricación y comercio minorista?

En vehículos autónomos, cámaras, lidar, radar y otros sensores contribuyen a construir una representación tridimensional del entorno: la detección, segmentación y comprensión de la escena ayudan a identificar peatones, vehículos, carriles y

señales para navegar. En fabricación, la inspección visual detecta defectos o incongruencias en productos, y la segmentación puede localizar fallas con mayor precisión

9. ¿Qué bibliotecas y marcos de código abierto menciona IBM?

IBM enumera Keras, API para construir modelos de aprendizaje profundo que puede trabajar sobre TensorFlow o PyTorch; OpenCV, biblioteca de procesamiento de imágenes, detección y análisis de video; scikit-image, conjunto de algoritmos de procesamiento y segmentación en Python; TensorFlow, plataforma de aprendizaje automático con recursos para clasificación, detección y segmentación; y torchvision, biblioteca del ecosistema PyTorch que ofrece transformaciones, conjuntos de datos y modelos visuales. PyTorch aparece como marco asociado a Keras y torchvision. La elección depende de la tarea: procesamiento clásico, preparación de datos o entrenamiento de modelos profundos.

10. ¿Qué retos éticos y técnicos enfrenta la visión artificial?

El artículo de IBM no desarrolla de forma explícita privacidad, sesgos ni interpretabilidad; los puntos siguientes son un análisis derivado de sus aplicaciones y de su énfasis en la calidad de los datos.

Privacidad: el reconocimiento facial y el análisis de imágenes de personas pueden tratar datos sensibles, por lo que deben limitarse la captura, el acceso y el uso. Sesgos: un conjunto de entrenamiento poco diverso o mal etiquetado puede producir errores desiguales entre contextos o grupos. Interpretabilidad: una predicción, sobre todo en medicina, debe poder revisarse y contrastarse con la imagen y con criterios profesionales. En lo técnico, también importan la calidad de las imágenes, la capacidad de generalizar a situaciones nuevas y la validación antes de usar resultados en decisiones de alto impacto.

Fuente

Caballar, R. D., y Stryker, C. (2025, 17 de septiembre). *¿Qué es la visión artificial?* IBM. https://www.ibm.com/mx-es/think/topics/computer-vision